

# 机器学习股票预测策略完整判断流程说明

策略代码: `code/src/predict.py`

生成日期: 2026 年 5 月 25 日

## 1 策略目标

本策略的目标不是单纯选出模型分数最高的五只股票，而是在模型预测分数的基础上叠加市场主题、科技子板块强弱、价格形态、量能换手、风险剔除和组合权重控制，形成更接近实盘选股逻辑的五股票组合。

当前策略重点解决三个问题：

1. 识别当前科技主线是否强于全市场，并把资金更多分配给强科技分支。
2. 避免只因为主题相似而买入高位放量退潮票。
3. 在强主题和模型原始预测之间做平衡，保留少量非主题高模型分数票作为分散。

## 2 整体流程



## 3 数据使用口径

### 3.1 正式预测口径

正式预测时，策略使用数据文件中的最新交易日作为预测日。模型序列、个股价格特征、成交额、换手率、主题相似度、科技强弱和风险信号都基于预测日及之前的数据计算。

如果 AkShare 实时行情可用，策略会额外加入实时涨跌幅、成交额、换手率、量比和实时破位判断。如果实时行情不可用，则自动退化为仅使用历史信号。

### 3.2 回测口径

单窗口回测可以指定：

- 预测日：例如 2026-04-24，只允许模型和个股信号看到该日及以前。
- 买入日：例如 2026-04-27，使用开盘价买入。
- 卖出日：例如 2026-04-30，使用开盘价卖出。

- 主题画像口径：可以严格只用预测日以前，也可以用指定月份的主题画像。若使用 5 月主题画像，本质是把「五月主线偏好」作为外部先验，但个股走势信号仍不看买入后的答案。

## 4 股票池与主题划分

### 4.1 主题种子池

主题画像使用若干代表性股票作为种子，覆盖电网设备、通信、电池、机器人等成长方向。种子股票用于拟合当前主题行情的价格形态均值和尺度。

| 主题   | 代表股票                               |
|------|------------------------------------|
| 电网设备 | 600406、002028、600089、600312        |
| 通信   | 300308、300502、000063、300394、601138 |
| 电池   | 300750、300014                      |
| 机器人  | 002050、300124                      |

### 4.2 科技攻击池

科技攻击池用于识别更有进攻性的科技线，包括半导体设备、芯片设计、晶圆制造材料、AI 硬件和通信硬件。代码中进一步拆成四个科技子板块：

| 子板块      | 股票                                        |
|----------|-------------------------------------------|
| AI 硬件与通信 | 300308、300502、300394、300476、601138、000063 |
| 半导体设备    | 002371、688012、688008                      |
| 芯片设计     | 688041、603501、603986、300782、002049、688256 |
| 晶圆制造与材料  | 688981、600584、688126、688396               |

## 5 个股基础信号

每只股票基于预测日前的历史开盘价序列计算以下信号：

- 短期收益：ret\_3、ret\_5、ret\_10、ret\_20。
- 波动率：最近 20 日日收益标准差 vol\_20。
- 均线偏离：相对 5 日、20 日、60 日均线的位置。

- 回撤和支撑：相对 20 日、60 日高点的回撤，以及相对 20 日低点的支撑距离。
- RSI：14 日 RSI，归一化到 0 到 1。
- 超跌反弹：识别没有破位但处于短期超跌、接近支撑、短线企稳的股票。
- 阻力陷阱：识别接近阶段高点、涨幅较大、短线动能回落、RSI 偏高的股票。

## 6 主题画像与主题相似度

策略先对主题种子股票计算一组价格形态特征，包括短期收益、波动率、均线偏离、回撤、支撑距离、RSI 和超跌反弹状态。随后求出种子股票的均值向量和尺度向量，形成主题画像。

任意股票的主题相似度定义为：

$$\text{theme\_similarity} = \frac{1}{1 + \sqrt{\text{mean}\left(\left(\frac{x-\mu}{\sigma}\right)^2\right)}}$$

其中  $x$  是该股票的价格形态特征， $\mu$  是主题画像均值， $\sigma$  是主题画像尺度。相似度越高，说明它的形态越接近当前主题种子。

## 7 科技强度判断

### 7.1 个股科技动量

科技股票额外计算 `tech_momentum_score`。该分数综合：

- 5 日、10 日、20 日收益；
- 是否接近 20 日高点并有突破质量；
- 是否满足 10 日均线高于 20 日均线；
- 近 5 日成交额是否明显高于前 15 日；
- 是否短线急跌或 RSI 过热。

### 7.2 全局科技 regime

科技攻击池整体是否强于全市场，由以下三项决定：

$$\text{tech\_regime} = \overline{r_{5, \text{tech}}} - \overline{r_{5, \text{all}}} + 0.6 \cdot (P(r_{5, \text{tech}} > 0) - P(r_{5, \text{all}} > 0)) + 0.25 \cdot \overline{\text{tech\_momentum}}$$

当 `tech_regime > 0` 时，组合会把目标成长仓位提高到 `tech_total_weight = 0.82`；否则使用较保守的 `quiet_tech_total_weight = 0.62`。

7.3 科技子板块强度

每个科技子板块单独计算相对全市场的 5 日收益优势、上涨占比优势和科技动量均值。强子板块内的股票会获得额外加分，弱子板块不会因为同属科技而被无条件抬高。

8 风险识别与剔除

8.1 破位风险

若个股跌破 20 日低点、明显低于 60 日均线，或接近 60 日低点且 20 日收益明显为负，会触发 `breakdown`。触发后该股 `adjusted_score` 扣 3 分。

8.2 阻力陷阱

阻力陷阱用于识别高位附近动能衰减的股票。信号包括：

- 接近 20 日或 60 日高点；
- 相对 20 日或 60 日均线涨幅过大；
- 3 日、5 日动能减弱；
- 5 日收益明显弱于 10 日收益；
- RSI 偏高。

阻力分 `resistance_score` 会按 `resistance_penalty_weight = 0.85` 扣分；若达到陷阱阈值，则额外扣 1.2 分并从优先候选池剔除。

8.3 放量高换手派发风险

这是针对 300394 案例新增的关键风控。它识别「高位、放量、高换手、连续大阴回落」这类可能退潮的股票。

派发风险 `distribution_risk` 的规则如下：

| 条件                                       | 风险加分  |
|------------------------------------------|-------|
| 3 日收益低于 -2.5%，且 5 日成交额均值高于 20 日均值 10% 以上 | +0.45 |
| 5 日收益低于 -4%，且 5 日换手率均值高于 20 日均值 15% 以上   | +0.35 |
| 当前价低于 5 日均线 2% 以上，且 20 日收益仍高于 5%         | +0.25 |
| 20 日波动率高于 3.5%，且成交额仍放大                   | +0.15 |

5 日收益低于 -6%

+0.20

总风险最高截断到 1.25。当风险分达到 0.75 及以上时，触发 `distribution_trap`，该股票从优先候选池剔除，并额外扣 1 分。

## 9 综合打分公式

最终排序分 `adjusted_score` 的主体为：

$$\begin{aligned} \text{adjusted\_score} = & 1.00 \cdot z(\text{model\_score}) + 0.18 \cdot z(r_5) + 0.22 \cdot z(r_{20}) \\ & - 0.16 \cdot z(\text{vol}_{20}) + 0.35 \cdot \text{oversold\_rebound} + 1.15 \cdot z(\text{theme\_similarity}) \\ & + 0.35 \cdot I(\text{core\_growth}) + 0.85 \cdot I(\text{tech\_attack}) \\ & + 0.45 \cdot z(\text{tech\_momentum}) \cdot I(\text{tech\_attack}) \\ & + 0.55 \cdot \text{tech\_regime} \cdot I(\text{tech\_attack}) \\ & + 0.85 \cdot \text{tech\_subsector\_strength} \cdot I(\text{tech\_attack}) \end{aligned}$$

随后叠加以下扣分：

$$\begin{aligned} \text{adjusted\_score} \text{ --} & 3.0 \cdot I(\text{breakdown}) \\ & + 1.5 \cdot I(\text{rt\_breakdown}) \\ & + 0.85 \cdot \text{resistance\_score} + 1.2 \cdot I(\text{resistance\_trap}) \\ & + 1.15 \cdot \text{distribution\_risk} + 1.0 \cdot I(\text{distribution\_trap}) \end{aligned}$$

## 10 组合构建规则

1. 先过滤掉 `breakdown`、`rt_breakdown`、`resistance_trap`、`distribution_trap` 的股票。
2. 若过滤后不足五只，则逐级放松过滤条件，保证可输出组合。
3. 在前 120 个高 `adjusted_score` 股票中，优先选择 3 只成长主题候选。
4. 再用模型原始分数排名补足到 5 只，避免主题因子完全覆盖模型判断。
5. 对五只股票按  $\exp(\text{score}/0.75)$  计算初始权重。
6. 若成长主题股和非主题股同时存在，则成长主题总仓位按 `target_growth_weight` 分配。
7. 单只成长股权重上限为 35%，非核心股权重上限为 15%。
8. 权重四舍五入到 4 位小数，并修正最后的舍入误差，使总权重为 1。

## 11 300394 案例说明

在 2026-04-24 截面，300394 的主题属性较强，且属于 AI 硬件与通信子板块。如果只看 5 月主题画像，它会被推入组合。但该股当时已经出现明显风险信号：

| 信号               | 数值     |
|------------------|--------|
| 2026-04-23 单日涨跌幅 | -6.74% |
| 2026-04-24 单日涨跌幅 | -7.49% |
| 近 5 日收益          | -5.41% |
| 近 20 日收益         | +7.59% |
| 5 日/20 日成交额比     | 1.28   |
| 5 日/20 日换手率比     | 1.24   |

这些特征组合意味着它不是普通回调，而更像高位放量分歧后的退潮信号。新增派发风险后，300394 会触发较高的 `distribution_risk`，并被排除出优先候选池。

在 2026-04-24 预测、2026-04-27 开盘买入、2026-04-30 开盘卖出的测试中，替换掉 300394 后，组合加入 688012，收益率由约 +1.02% 提升到约 +3.22%。

## 12 当前策略输出文件

正式运行 `python code/src/predict.py` 后，主要输出：

- `output/result.csv`：最终五只股票和权重。
- `output/selection_details.csv`：入选股票的完整信号和权重。
- `output/signal_scores.csv`：全部候选股票的信号分数。
- `output/theme_profile_seeds.csv`：主题画像种子股票特征。

## 13 策略边界

- 当前策略仍是规则增强型模型组合，不保证未来收益。
- 科技主题画像如果使用未来月份信息，只适合作为研究或外部先验模拟，不能算严格无未来函数回测。
- 新增派发风险能过滤类似 300394 的高位放量退潮票，但也可能错杀洗盘后继续上涨的强势票。
- 最终应继续用更多月份、多窗口、不同市场环境验证参数稳定性。